


PRÁCTICA 2

1.- Imagen 1

Esta imagen es un 5, pero el modelo la clasifica como un 1. Para hacer que el modelo la clasifique como un 5, la técnica que ha funcionado ha sido hacer gradient ascent sobre la imagen para que se maximice la probabilidad de que prediga un 5. Para mantener la restricción de modificar como mucho el 40% de los píxeles, he utilizado una máscara. Esa máscara son los “píxeles problemáticos” identificados con integrated gradients (son los píxeles que llevan la predicción a 1 en vez de a 5. Me he quedado con el 39% de los píxeles más problemáticos, porque, con menos, la técnica no surtía efecto). La imagen resultante es la siguiente:



Otras pruebas (fallidas) han incluido crear esta máscara con otras técnicas de explicabilidad (saliency maps, grad_cam, grad_cam ++, occlusion maps) y cambiar los píxeles con técnicas manuales (por ejemplo: aclarar los píxeles que llevan la predicción a 5, y oscurecer los que la llevan a 1, cambiar los píxeles problemáticos por colores aleatorios, difuminar la imagen en los píxeles problemáticos -identificados con varias técnicas-, ver qué imágenes del dataset clasifica correctamente como 5 -ninguna- para intentar que se parezca a ella, etc).

2.- Imagen 2

Esta imagen es un 3, pero el modelo la clasifica como un 1. La técnica que ha funcionado en este caso ha sido cambiar los píxeles que integrated gradients ha identificado como problemáticos (el 38% superior para no sobrepasar el 40% y que funcionara) por blanco. La imagen resultante es:



El resto de las pruebas son parecidas a las del caso anterior, con la diferencia de que, en este caso, usar gradient ascent con una máscara (calculada de diferentes formas a partir de los resultados de integrated gradients, saliency maps, cam y combinaciones) no ha funcionado.

3.- Imagen 3

Esta imagen es un 3, pero el modelo la clasifica como un 1. En este caso, el proceso realizado ha sido igual que en la imagen 2, con el mismo resultado. De nuevo, la técnica que ha funcionado ha sido sustituir el 37% de los píxeles más problemáticos (detectados con integrated gradients) por blanco. La imagen resultante es:

**4.- Imagen 4**

Esta imagen es un 7 que el modelo clasifica como un 3. En este caso, la técnica que ha servido ha sido usando directamente la salida de integrated gradients. En este caso, he comparado la explicación de que clasifique un 7 con la explicación de clasificar un 3. Después he aplicado una máscara que oscurece los píxeles que llevan la predicción a 3 y resalta (aclara) los píxeles que la llevan a 7. La imagen resultante es:

**5.- Imagen 5**

Esta imagen es un 2 que el modelo clasifica como un 6. En este caso, al ver la salida de la explicación con integrated gradients, he visto que había pocos píxeles “problemáticos” y que el problema estaba, principalmente en la parte inferior izquierda de la imagen (con un parche negro). Observando las imágenes que el modelo clasifica correctamente como 2 en el dataset, he visto que esto podía ser la única causa. Por tanto, he tapado la mancha negra con un cuadrado blanco y otro negro superpuesto para simular el borde del número. Con este cambio, la predicción ya era correcta. La imagen queda:

